Université de Toulouse

Projet Données Multimédia Master 2 Statistique et Informatique Décisionnelle

Analyse exploratoire du corpus EmoVid

Objectif : reconnaissance d'émotions dans des extraits de films





Fournisseurs :

Ousmane TALL

Ghislain NEZERWE

Ikenna UDEANI

Fatima Ez Zahra IDALI

Clients

PINQUIER Julien

FARINAS Jerome

RADOUANE Karim

Année universitaire 2026-2027

Sommaire

1. Introduction..... 2
2. Présentation du corpus..... 2
3. Contrôles de qualité..... 3
4. Répartition des émotions..... 4
5. Variables numériques.....5
5.1 Durée des extraits..... 5
5.2 Luminosité et colorimétrie..... 6
5.3 Teinte.....6
5.4 Relation entre luminosité et colorimétrie..... 7
6. Variables visuelles et émotions..... 7
7. Conséquences pour la suite du projet.....8
8. Conclusion..... 9

1. Introduction

Le projet consiste à construire un système de reconnaissance de huit catégories d'émotions (*amusement*, *awe*, *contentment*, *excitement*, *anger*, *disgust*, *fear*, *sadness*) dans des extraits de films, à partir de trois modalités : le texte, l'audio et la vidéo. Les données proviennent d'une sous-partie du corpus EmoVid (section « movie »).

Avant toute modélisation, une analyse exploratoire est nécessaire. Elle permet de vérifier l'intégrité des données, de repérer d'éventuels déséquilibres et de comprendre les caractéristiques des extraits. Ses conclusions orientent les choix à venir : construction de la partition entraînement / développement / test, métriques d'évaluation, traitement des modalités.

2. Présentation du corpus

Le jeu de données contient **3 088 extraits** issus de **350 films**, soit environ 8,8 extraits par film. Il est organisé en trois dossiers parallèles : « annotation », « audio » et « video ». Chacun comporte un sous-dossier par film (identifié par un numéro à cinq chiffres) et un fichier par extrait, nommé selon le motif *numéro-du-film_clip_numéro-de-l'extrait*. Les annotations sont au format JSON, les sons au format MP3 et les vidéos au format MP4.

Chaque annotation décrit un extrait à l'aide des champs suivants :

Tableau 1 : champs des annotations JSON

Champ	Type	Contenu
video_id	texte	Identifiant de l'extrait (ex. 00306_clip_013), dont on déduit le film
emotion	catégorielle	Émotion annotée parmi les huit classes
caption	texte	Description en langue anglaise de la scène
brightness	numérique	Luminosité de l'extrait (0 à 0,6 dans ce corpus)
colorfulness	numérique	Colorimétrie de l'extrait (0,1 à 1)
hue	numérique	Teinte dominante, en degrés (0 à 359)
duration	numérique	Durée de l'extrait, en secondes

Deux remarques sur le décompte. D'une part, le sujet mentionne 3 439 extraits alors que le jeu effectivement distribué en contient **3 088** : nous travaillons sur ces 3 088 extraits, sans expliquer l'écart. D'autre part, le dossier « vidéo » affiche un élément de plus que les deux autres (351 éléments pour 350 films, 3 089 fichiers pour 3 088 extraits). Cet élément supplémentaire est un fichier système de macOS (*.DS_Store*), sans rapport avec les données.

3. Contrôles de qualité

Nous avons vérifié l'absence de valeurs manquantes, de doublons et d'incohérences, ainsi que la présence des fichiers audio et vidéo associés à chaque annotation.

Tableau 2 : contrôles de qualité du jeu de données

Vérification	Résultat	Interprétation
Valeurs manquantes	0 dans toutes les colonnes	Aucune donnée à imputer
Lignes entièrement dupliquées	0	Aucun doublon
Identifiants video_id dupliqués	0	Chaque extrait apparaît une seule fois
Vidéos présentes	3 088 sur 3 088	Une vidéo par annotation
Audios présents	3 088 sur 3 088	Un fichier audio par annotation
Durées nulles ou négatives	0	Durées cohérentes
Classes d'émotions	8 sur 8	Toutes les classes attendues sont présentes

Ces résultats sont favorables : le corpus est propre et ne nécessite aucun nettoyage. Comme chaque extrait dispose de ses trois modalités (texte via la description et la transcription, audio, vidéo), la fusion multimodale pourra être réalisée sur l'ensemble des extraits.

4. Répartition des émotions

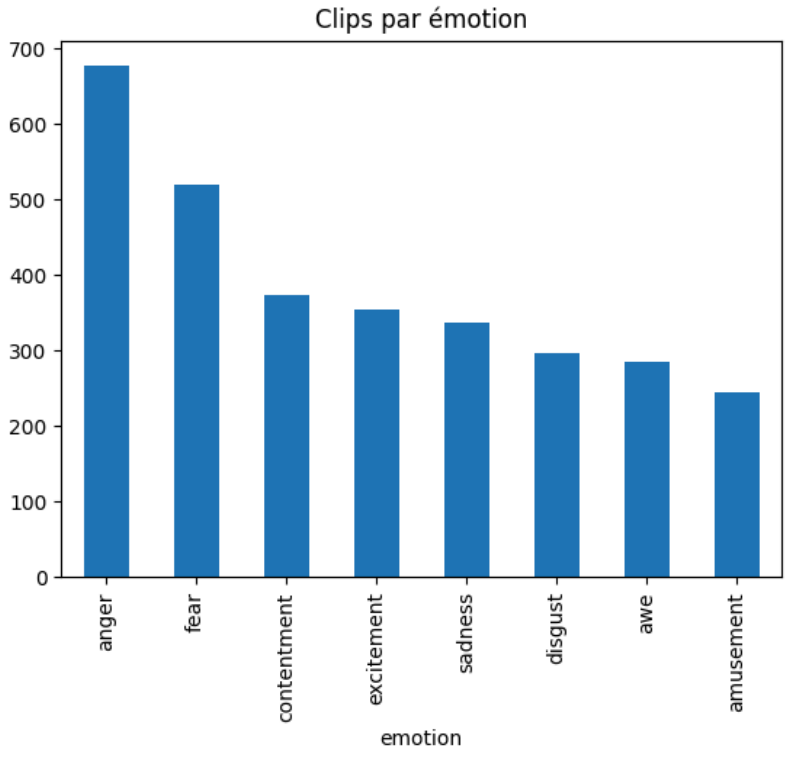


Figure 1 : nombre d'extraits par émotion

Tableau 3 : effectifs par émotion (extraits et films contenant l'émotion)

Émotion	Extraits	Part du corpus	Films concernés	Part des films
Colère (*anger*)	677	21,9 %	223	64 %
Peur (*fear*)	519	16,8 %	171	49 %
Satisfaction (*contentment*)	373	12,1 %	140	40 %
Excitation (*excitement*)	354	11,5 %	151	43 %
Tristesse (*sadness*)	338	10,9 %	133	38 %
Dégoût (*disgust*)	297	9,6 %	146	42 %
Émerveillement (*awe*)	286	9,3 %	120	34 %
Amusement (*amusement*)	244	7,9 %	96	27 %
Total	**3 088**	**100 %**	**350 films**	

Lecture. Le diagramme en barres (figure 1) montre un net déséquilibre entre les classes. La colère (*anger*) est la plus représentée avec 677 extraits (21,9 %), suivie de la peur (*fear*) avec 519 extraits (16,8 %). Les six autres classes se situent entre 12,1 % (*contentment*) et 7,9 % (*amusement*), la classe la moins représentée avec 244 extraits. Le rapport entre la plus grande et la plus petite classe est d'environ 2,8. Seules *anger* et *fear* dépassent nettement la part qu'aurait une répartition uniforme (12,5 %).

Le tableau 3 apporte un second enseignement. Un même film contient des extraits d'émotions différentes : la colère apparaît dans 223 des 350 films (64 %), la peur dans 171 (49 %), alors que l'amusement n'apparaît que dans 96 films (27 %). Un film n'a donc pas une étiquette unique, ce qui complique la constitution d'une partition par films équilibrée en classe.

Conséquences. Prédire systématiquement *anger* donnerait une exactitude (*accuracy*) d'environ 22 % sans rien apprendre : l'exactitude est trompeuse sur ce corpus. Nous retiendrons la **macro-F1** (moyenne des F1 par classe) comme métrique principale, et nous commencerons le déséquilibre à l'entraînement par des poids de classes. Enfin, les classes rares seront évaluées sur peu d'exemples (environ 35 extraits d'*amusement* dans les ensembles de développement et de test), ce qui rend leurs scores individuels sensibles au hasard.

5. Variables numériques

Tableau 4 : statistiques descriptives des variables numériques

Variable	Moyenne	Médiane	Minimum	Maximum
duration (s)	8,14	6,42	4,00	29,82
brightness	0,206	0,200	0,000	0,600
colorfulness	0,337	0,300	0,100	1,000
hue (°)	75,4	31	0	359

5.1 Durée des extraits

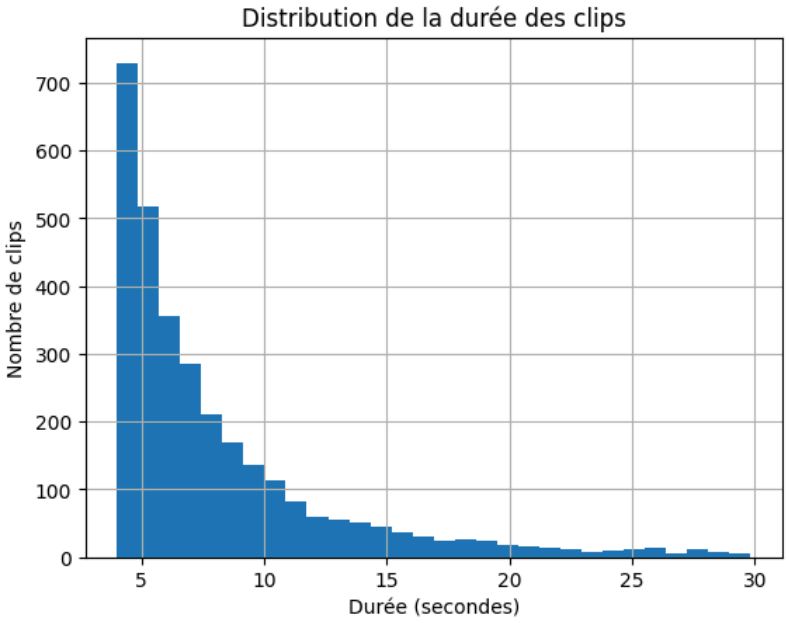


Figure 2 : distribution de la durée des extraits

L'histogramme est fortement asymétrique à droite. Les extraits courts dominent : la classe la plus haute, juste au-dessus de 4 s, regroupe environ 730 extraits, et les effectifs décroissent ensuite régulièrement jusqu'à une longue traîne qui atteint près de 30 s. La moyenne (8,14 s) dépasse nettement la médiane (6,42 s), signe de cette asymétrie : la moitié des extraits dure moins de 6,4 s et aucun ne dure moins de 4 s.

Pour la modélisation, les extraits n'ont pas une durée fixe. Les représentations audio et vidéo devront donc être résumées sur le temps (par exemple par une moyenne des représentations image par image ou fenêtre par fenêtre) afin d'obtenir des vecteurs de même taille, quelle que soit la durée.

5.2 Luminosité et colorimétrie

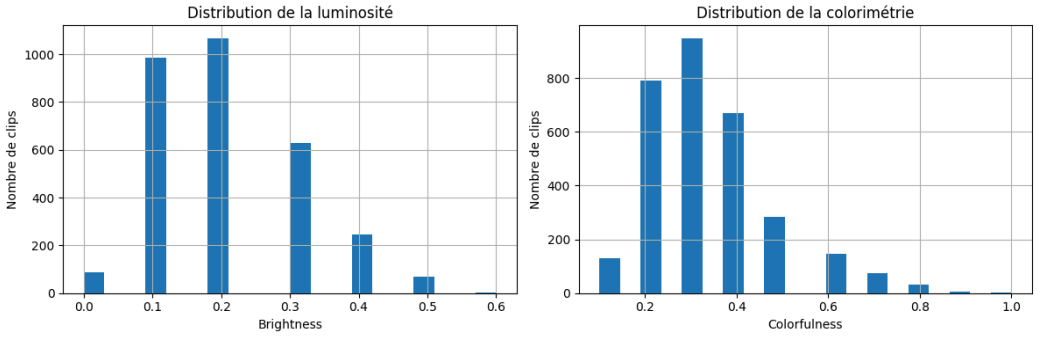


Figure 3 : distributions de la luminosité (gauche) et de la colorimétrie (droite)

Les deux variables ne prennent que des valeurs discrètes, par pas de 0,1 : elles ont été arrondies dans les annotations, ce qui explique les barres séparées. La luminosité se concentre sur 0,1 et 0,2 (environ 1 000 extraits chacune) puis décroît rapidement ; au-delà de 0,4, les extraits sont rares et aucun ne dépasse 0,6. La colorimétrie présente un mode à

0,3 (environ 950 extraits), la majorité des valeurs se situant entre 0,2 et 0,4, avec une queue vers les valeurs élevées qui atteint 1,0.

Le corpus est donc globalement composé d'extraits plutôt sombres et peu saturés, ce qui est plausible pour des scènes de films. L'arrondi à 0,1 limite toutefois la finesse de ces deux descripteurs.

5.3 Teinte

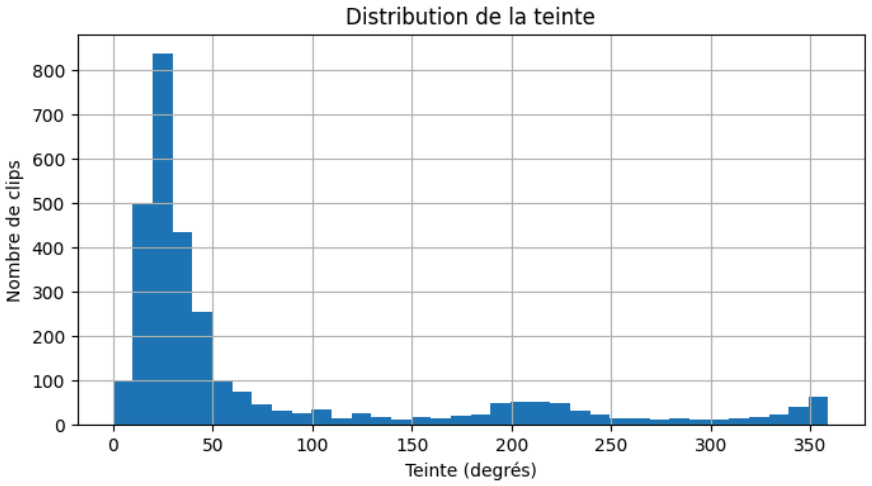


Figure 4 : distribution de la teinte dominante

La distribution est très concentrée entre 10° et 50°, avec un pic autour de 25° (environ 840 extraits dans la classe la plus haute) : la teinte dominante est le plus souvent dans les tons chauds, du rouge-orangé au jaune. On observe aussi un petit renflement entre 190° et 230° (tons bleus), puis une remontée vers 340°–359°. Comme la teinte est une variable circulaire, 359° est voisin de 0° : cette remontée correspond au même domaine des rouges que le pic principal.

Pour cette raison, la moyenne (75,4°) est peu représentative ; la médiane (31°) décrit mieux le corpus. La dominance des tons chauds s'explique probablement par les teintes de peau et les éclairages chauds du cinéma, mais cette hypothèse n'est pas vérifiée ici.

5.4 Relation entre luminosité et colorimétrie

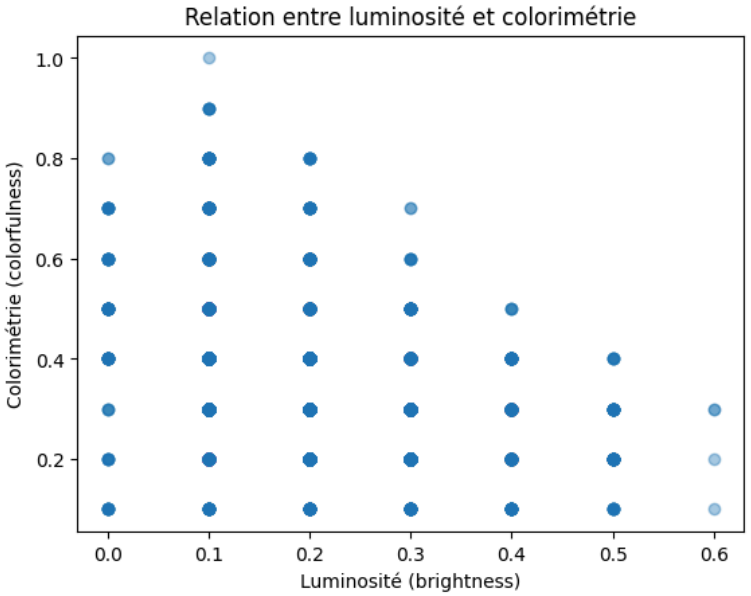


Figure 5 : nuage de points luminosité – colorimétrie

Les valeurs étant discrètes, le nuage de points forme une grille (figure 5). On y distingue néanmoins une forme triangulaire : la région en haut à droite est vide. Les extraits les plus lumineux ne sont jamais très colorés : pour une luminosité de 0,4, la colorimétrie ne dépasse pas 0,5 ; pour 0,5, elle reste à 0,4 au plus ; pour 0,6, à 0,3. Le coefficient de corrélation est de **−0,354**, ce qui indique une relation linéaire négative modérée : plus un extrait est lumineux, plus sa colorimétrie tend à être faible, sans que cette tendance soit systématique.

6. Variables visuelles et émotions

Nous avons ensuite cherché si la luminosité et la colorimétrie varient selon l'émotion annotée.

Tableau 5 : luminosité et colorimétrie moyennes par émotion

Émotion	Luminosité moyenne	Colorimétrie moyenne
amusement	0,203	0,371
anger	0,220	0,342
awe	0,198	0,330
contentment	0,209	0,308
disgust	0,228	0,326
excitement	0,227	0,340
fear	0,180	0,336
sadness	0,181	0,344

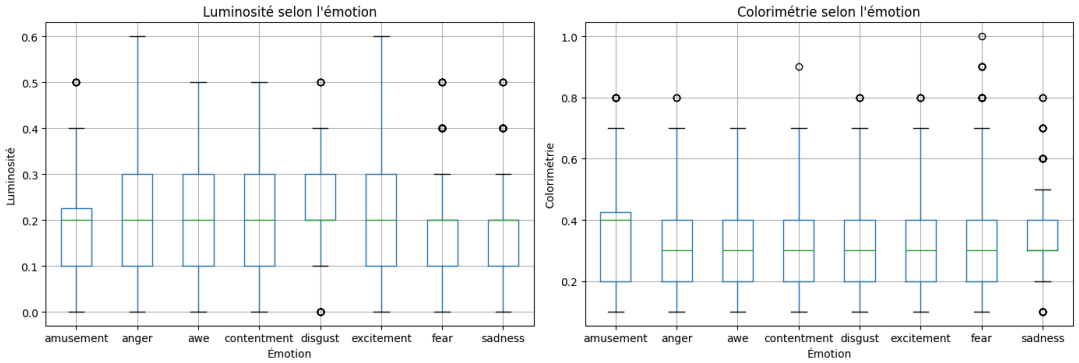


Figure 6 : luminosité (gauche) et colorimétrie (droite) selon l'émotion

Les moyennes (tableau 5) varient peu d'une émotion à l'autre : de 0,180 à 0,228 pour la luminosité, de 0,308 à 0,371 pour la colorimétrie. Les extraits de peur (0,180) et de tristesse (0,181) sont les moins lumineux, ceux de dégoût (0,228) et d'excitation (0,227) les plus lumineux. L'amusement se distingue par la colorimétrie moyenne la plus élevée (0,371), la satisfaction par la plus faible (0,308).

Les boîtes à moustaches (figure 6) confirment ce constat. Pour la luminosité, la médiane vaut 0,2 pour toutes les émotions, mais le troisième quartile est à 0,2 pour la peur et la tristesse contre 0,3 pour la plupart des autres : ces deux émotions sont donc plutôt associées à des scènes plus sombres. Pour la colorimétrie, la médiane est proche de 0,3 partout, sauf pour l'amusement (0,4), dont la boîte est aussi plus étendue. Dans tous les cas, les boîtes se chevauchent largement et l'on observe des valeurs atypiques, notamment pour la peur et la tristesse en colorimétrie.

Limites de cette lecture. Il s'agit d'un constat descriptif : aucun test statistique n'a été mené pour savoir si les écarts de moyennes sont significatifs. Par ailleurs, l'arrondi à 0,1 fait coïncider artificiellement beaucoup de médianes. Ces variables apportent probablement une information utile, mais trop faible pour distinguer à elles seules les huit émotions.

7. Conséquences pour la suite du projet

L'analyse conduit aux choix suivants :

- **Partition par films.** Les extraits d'un même film partagent acteurs, ambiance sonore et style visuel. Ils doivent rester dans un même ensemble afin que l'évaluation porte sur des films inconnus. La partition commune retenue (fichier du groupe 1) répartit les 350 films en 250 pour l'entraînement, 50 pour le développement et 50 pour le test, soit 2 207, 442 et 439 extraits, en conservant les proportions d'émotions du corpus (par exemple 98 extraits de colère en développement et 96 en test).
- **Métrique et déséquilibre.** La macro-F1 est la métrique principale, complétée par des poids de classes à l'entraînement. La valeur du hasard (huit classes) est de 12,5 %.
- **Durées variables.** Les représentations audio et vidéo seront résumées sur le temps pour obtenir une taille fixe quelle que soit la durée.
- **Descripteurs visuels simples insuffisants.** Il faudra exploiter le contenu même des trois modalités (parole et description textuelle, signal sonore, images) plutôt que ces seuls indicateurs.

- **Données complètes.** Tous les extraits possédant leurs fichiers audio et vidéo, la fusion des modalités pourra se faire sur l'ensemble du corpus.

8. Conclusion

L'analyse exploratoire a permis de caractériser le corpus : 3 088 extraits issus de 350 films, répartis en huit émotions, avec leurs fichiers audio et vidéo disponibles et sans valeur manquante ni doublon. Le jeu de données est propre et directement exploitable.

Deux caractéristiques ressortent. D'une part, un **déséquilibre des classes** : la colère (22 % des extraits) et la peur (17 %) dominent, tandis que l'amusement (8 %) est la classe la plus rare. Un même film mélangeant plusieurs émotions, l'équilibrage de la partition se fait au niveau des extraits. Ce déséquilibre impose la macro-F1 comme métrique et rend l'évaluation des classes rares plus incertaine. D'autre part, des **extraits de durée variable** (de 4 à près de 30 s, médiane de 6,4 s), qu'il faudra résumer sur le temps.

Les descripteurs visuels des annotations (luminosité, colorimétrie, teinte) montrent des tendances cohérentes : extraits plutôt sombres, peu saturés et de dominante chaude, les scènes de peur et de tristesse étant légèrement plus sombres et celles d'amusement légèrement plus colorées. Mais leurs distributions se chevauchent fortement d'une émotion à l'autre : ils ne suffisent pas à reconnaître les émotions, ce qui justifie le recours à des modèles exploitant le texte, l'audio et la vidéo.

Cette analyse a ses limites. Elle est purement descriptive, sans test statistique, et porte sur l'ensemble des 3 088 extraits, y compris ceux du futur ensemble de test, sans avoir servi à régler un modèle. Les variables visuelles sont arrondies à 0,1, et les descriptions textuelles (*caption*) n'ont pas été explorées ici : elles relèvent de la partie consacrée à la modalité texte. Ces observations servent de base à la suite du projet : modélisation de chaque modalité, puis fusion.