Synthèse des expérimentations Modalité vidéo

Ce document présente une synthèse des principales expérimentations réalisées pour la modalité vidéo dans le cadre du projet EmoVid. Il résume les représentations visuelles et les classifieurs testés, les principaux résultats obtenus ainsi que les raisons du choix du modèle final.

Tous les scores présentés correspondent aux résultats obtenus sur l'ensemble de validation (Dev). La métrique principale utilisée pour comparer les modèles est le F1-macro, complétée par l'accuracy.

Pour plus de détails sur les expérimentations, les graphiques et leurs interprétations, veuillez consulter le notebook video_experiments.ipynb.

1. Données et extraction des images

- Dataset de 3 088 vidéos, chacune associée à une émotion et à une partition (train, dev ou test).
- Extraction avec OpenCV de 8 images par vidéo à différents moments, redimensionnées avec un petit côté de 224 pixels (proportions conservées) et enregistrées au format NumPy (.npy).
- Test préalable sur 20 vidéos (3,69 s par vidéo en moyenne), puis extraction sur l'ensemble : 3 088 vidéos au statut OK, aucune erreur, soit 24 704 images.

2. Baseline : caractéristiques OpenCV

Pour chaque vidéo, 141 caractéristiques visuelles ont été calculées à partir des 8 images (couleurs, luminosité, contraste, changements entre images). Trois classifieurs ont été comparés après optimisation.

Modèle	F1-macro (Dev)	Accuracy (Dev)
Régression logistique optimisée	0,2011	0,2670
Random Forest optimisé	0,1980	0,2172
SVM optimisé	0,2224	0,2376

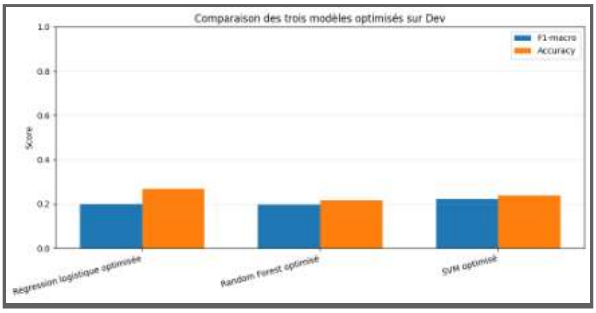


Figure 1 – Scores Dev des trois modèles OpenCV optimisés

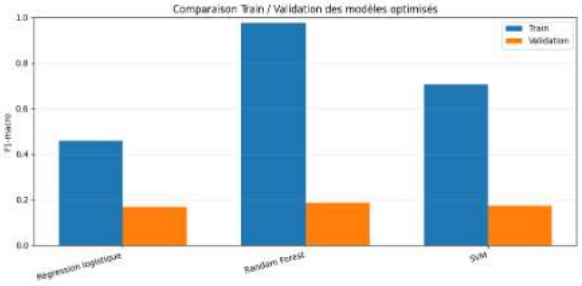


Figure 2 – F1-macro Train / Validation des trois modèles

> **Interprétation.** Les trois modèles restent faibles (F1-macro entre 0,198 et 0,222). Le Random Forest (train ≈ 0,97) et le SVM (train ≈ 0,71) surapprennent fortement, avec une validation à peine supérieure à 0,17. Les caractéristiques de bas niveau décrivent mal leémotions : elles servent de baseline, mais ne sont pas retenues.

3. Embeddings CLIP (openai/clip-vit-base-patch32)

Les embeddings CLIP (dimension 512) offrent une représentation visuelle plus riche que les caractéristiques OpenCV. Quatre classifieurs ont été testés dessus.

3.1 CLIP + régression logistique

F1-macro : 0,4058 – Accuracy : 0,4231 (configuration CLIP 512, solveur SAGA, sans pondération).

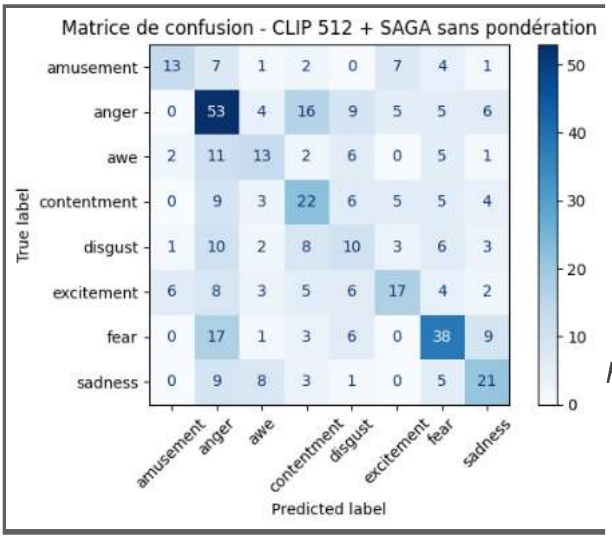


Figure 3 – Matrice de confusion (Dev)

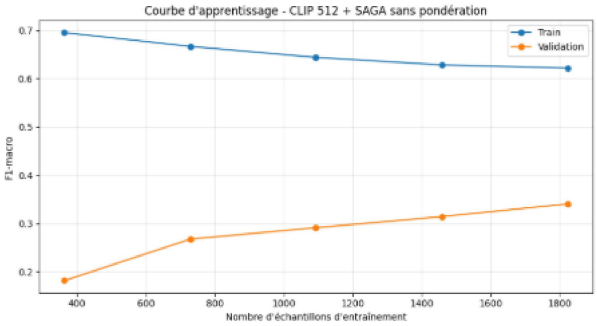


Figure 4 – Courbe d'apprentissage

> **Interprétation.** Anger (53 clips) et fear (38) sont les mieux reconnues ; disgust est souvent confondue avec anger et contentment. Le F1-macro de validation augmente avec la quantité de données (jusqu'à ≈ 0,34) et l'écart avec l'entraînement (0,69 → 0,62) se réduit : la généralisation est correcte.

3.2 CLIP + SVM (noyau RBF avec pondération)

F1-macro : 0,3673 – Accuracy : 0,3778

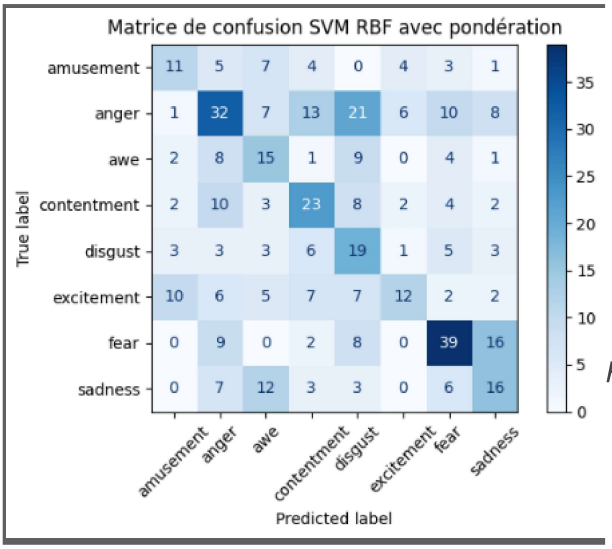


Figure 5 – Matrice de confusion (Dev)

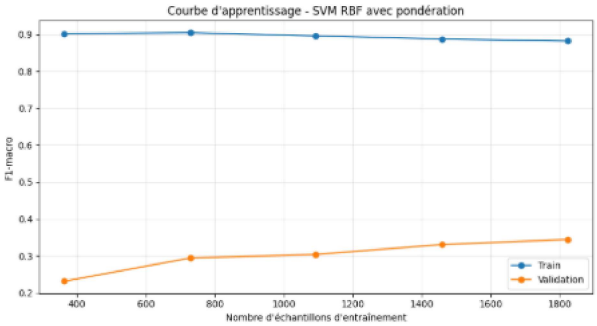


Figure 6 – Courbe d'apprentissage

> **Interprétation.** Fear (39), anger (32) et contentment (23) sont les mieux reconnues. Le SVM reste inférieur à la régression logistique et surapprend davantage (train ≈ 0,9 contre ≈ 0,35 en validation).

3.3 CLIP + MLP à une couche cachée

F1-macro : 0,4075 – Accuracy : 0,4072

Architecture : entrée 512 → Linear 256 → ReLU → Dropout → Linear 8.

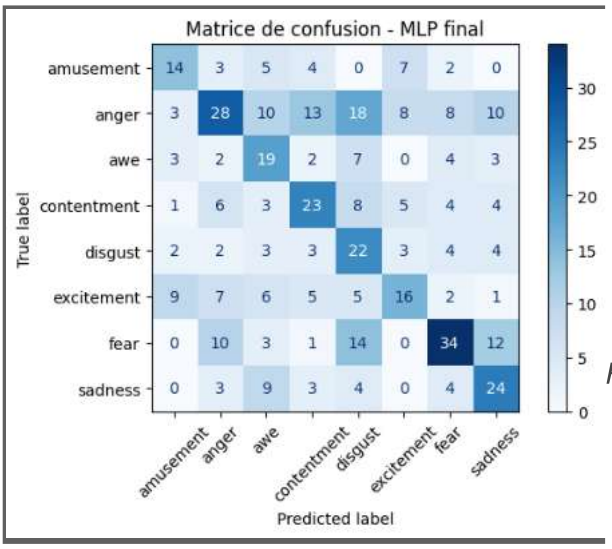


Figure 7 – Matrice de confusion (Dev)

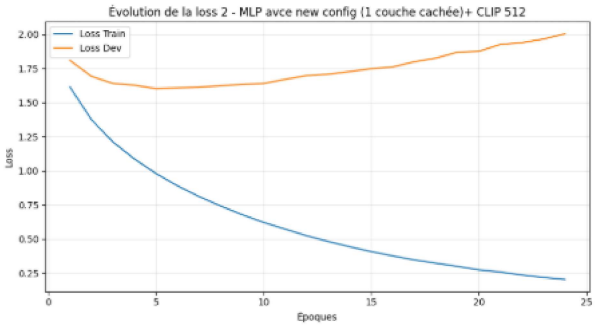


Figure 8 – Évolution de la loss (Train / Dev)

> **Interprétation.** Fear (34 sur 74), sadness (24 sur 47) et contentment (23 sur 54) sont les mieux détectées ; anger et disgust restent très confondues. La loss Dev remonte après quelques époques alors que la loss Train continue de baisser : le MLP surapprend et nécessite un arrêt précoce. Son F1-macro n'est supérieur à celui de la régression logistique que de 0,0017, et son accuracy est plus faible.

3.4 CLIP + MLP à deux couches cachées

Architecture plus profonde testée (optimisation avec Optuna). Le score global Dev n'est pas indiqué dans le document source ; le meilleur F1-macro Dev se situe autour de 0,40 (époque 4).

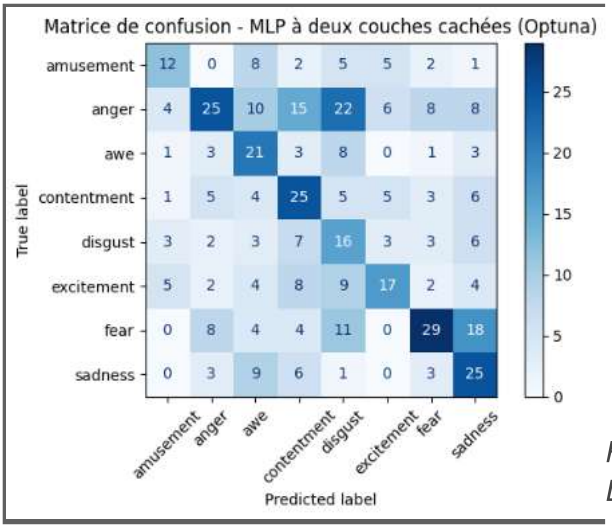


Figure 9 – Matrice de confusion (Dev)

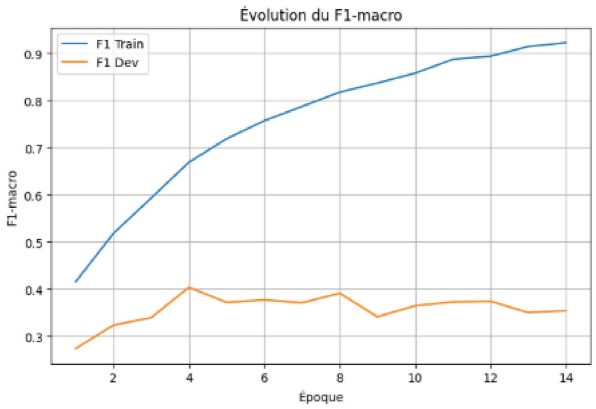


Figure 10 – Évolution du F1-macro (Train / Dev)

> **Interprétation.** Fear, sadness, contentment et awe sont les mieux reconnues ; la confusion principale reste anger → disgust. Le F1 d'entraînement monte vers 0,92 alors que le F1 Dev stagne entre 0,34 et 0,40 : une couche supplémentaire n'apporte pas de gain et accentue le surapprentissage.

3.5 CLIP + PCA + MLP

Meilleur F1-macro Dev : 0,3867

Architecture : entrée 128 composantes (PCA) → Linear 128 → ReLU → Dropout 0,4 → Linear 8.

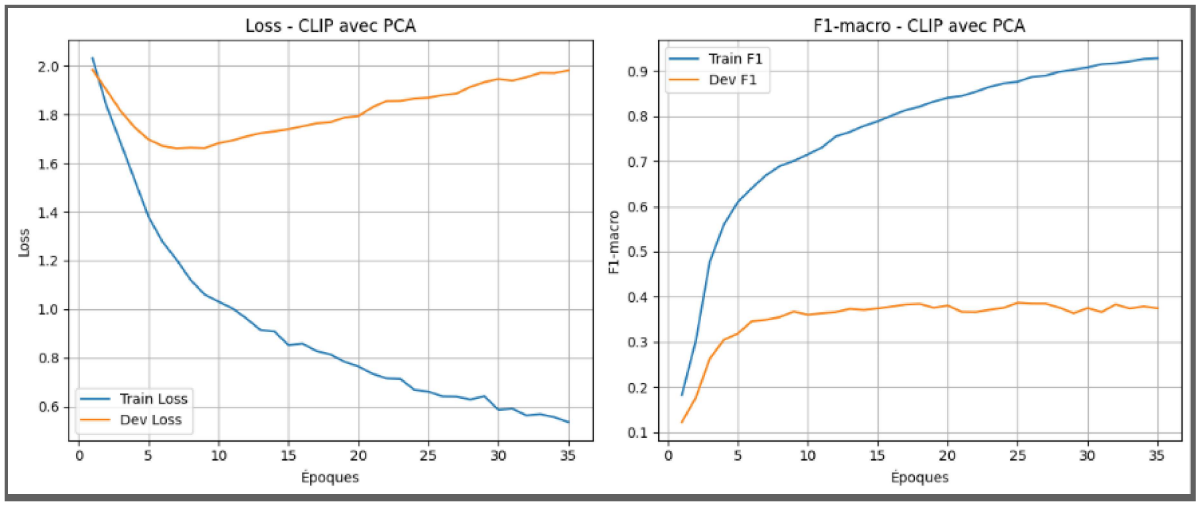
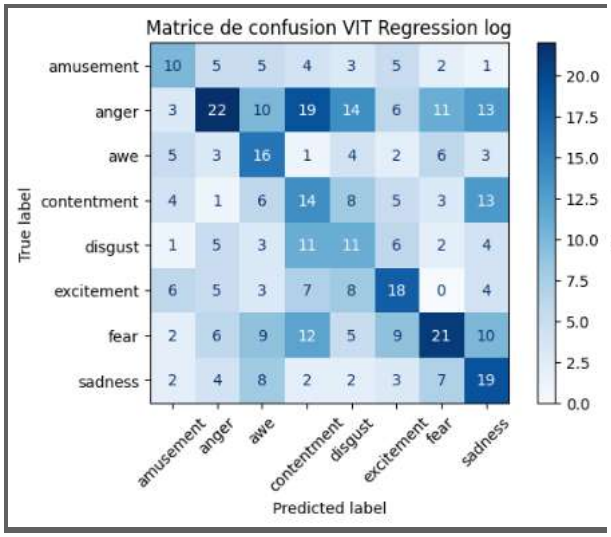


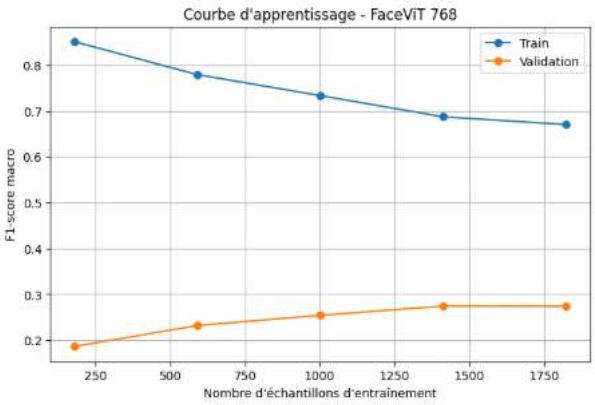
Figure 11 – Loss et F1-macro (Train / Dev) – CLIP avec PCA

> **Interprétation.** La réduction à 128 composantes allège les données mais fait baisser le score par rapport à CLIP sans PCA, et le surapprentissage persiste (loss Dev croissante, F1 Train proche de 0,93).

4. ViT Face Expression

F1-macro : 0,2962 – Accuracy : 0,2964 (embeddings 768 dimensions, régression logistique).





5. Fusion CLIP + ViT Face Expression

5.1 Régression logistique

F1-macro : 0,3793 – Accuracy : 0,3801

Figure 14 – Matrice de confusion (Dev)

Figure 15 – Courbe d'apprentissage

> **Interprétation.** La fusion ne dépasse pas CLIP seul (0,4058) : ajouter des dimensions n'apporte pas d'information utile supplémentaire.

5.2 MLP

Meilleur F1-macro Dev : 0,4008 (une couche cachée de 256 neurones).

Figure 16 – Loss et F1-macro (Train / Dev) – CLIP + ViT

> **Interprétation.** Le F1 d'entraînement atteint presque 1,0 contre ≈ 0,39 en validation, et la loss Dev augmente fortement : surapprentissage important, sans gain par rapport à CLIP seul.

6. Synthèse comparative

Représentation	Classifieur	Accuracy	F1-macro
OpenCV (baseline)	Régression logistique	0,2240	0,2111
OpenCV	Régression logistique	0,2670	0,2011
OpenCV	Random Forest	0,2172	0,1980
OpenCV	SVM	0,2376	0,2224
CLIP	**Régression logistique**	**0,4231**	**0,4058**
CLIP	SVM	0,3778	0,3673
CLIP	**MLP 1 couche cachée**	**0,4072**	**0,4075**
CLIP + PCA	MLP		0,3867
ViT Face Expression	Régression logistique	0,2964	0,2962
CLIP + Face Expression	Régression logistique	0,3801	0,3793
CLIP + Face Expression	MLP		0,4008

** Valeurs issues du tableau récapitulatif, qui diffèrent de celles des descriptions individuelles : à vérifier dans les notebooks. Toutes les valeurs sont sur Dev.*

7. Choix de Modele finale

Modèle retenu : CLIP + régression logistique (F1-macro 0,4058 ; accuracy 0,4231 sur Dev), pour les raisons suivantes :

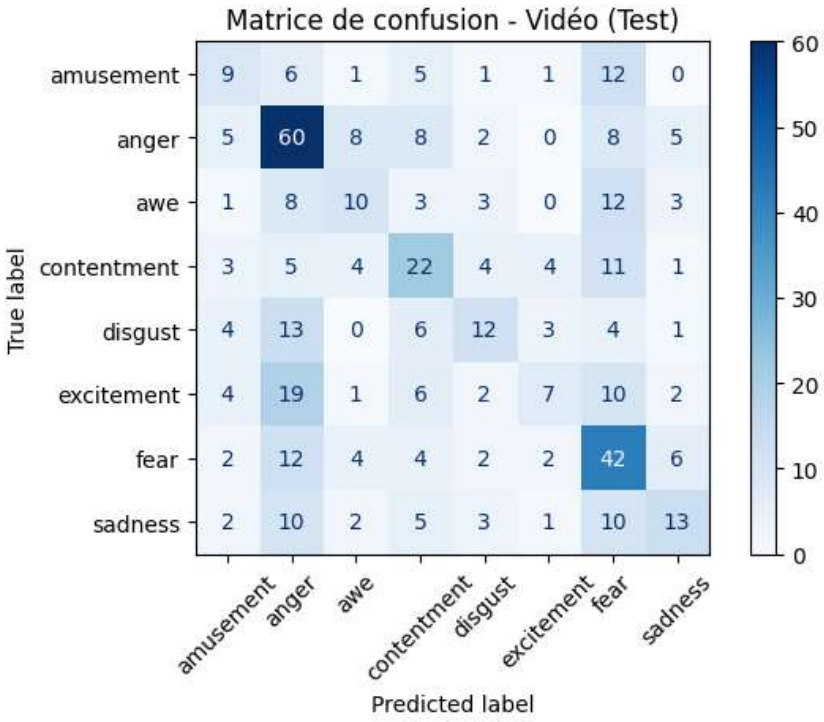
- CLIP apporte un gain net par rapport aux caractéristiques OpenCV (F1-macro d'environ 0,20 à plus de 0,40).
- Les meilleures configurations (régression logistique et MLP sur CLIP) sont équivalentes en F1-macro (0,4058 contre 0,4075), mais la régression logistique a la meilleure accuracy, est plus simple et généralise mieux : l'écart Train / Validation se réduit avec plus de données, alors que tous les MLP surapprennent.
- Les variantes plus complexes n'améliorent pas le résultat : PCA (0,3867), deux couches cachées, ViT Face Expression seul (0,2962) et fusion CLIP + ViT (0,3793 en régression logistique, 0,4008 en MLP).

Limites. Les résultats ci-dessus sont des résultats sur Dev ; la performance finale doit être mesurée sur Test, une seule fois, après la sélection. L'expérimentation ResNet-18 n'est pas documentée par des résultats chiffrés et devra être complétée à partir du notebook correspondant.

8. Évaluation finale sur Test

Le modèle retenu (CLIP + régression logistique) a été évalué sur l'ensemble de test.

- **Accuracy : 0,3986**
- **F1-macro : 0,3511**
- **Log Loss : 1,6892**



Points forts :

- Le modèle reconnaît très bien **anger** (60 prédictions correctes).
- Le modèle reconnaît bien **fear** (42 prédictions correctes).

Points faibles :

- Les émotions **amusement**, **awe**, **disgust**, **excitement** et **sadness** sont souvent confondues avec d'autres émotions.
- Par exemple, **excitement** est souvent prédit comme **anger** (19 fois).
- **awe** est souvent prédit comme **fear** (12 fois).

La matrice de confusion montre que le modèle distingue bien les émotions anger et fear, mais rencontre davantage de difficultés pour les émotions plus proches comme excitement, awe ou sadness, qui sont fréquemment confondues